

Lab04

AUTHOR

Leticia Rocha Soares Martins [221324]

Atividades

conversão para csv com duckdb

```
install.packages("duckdb")
library(duckdb)

fname <- file.path("dados", "WDIEXCEL.xlsx")
csv_saida <- file.path("dados", "WDIEXCEL_Data.csv")

con <- dbConnect(duckdb())
dbExecute(con, "INSTALL excel; LOAD excel;")
dbExecute(con, sprintf(
  "COPY (SELECT * FROM read_xlsx('%s', sheet = 'Data')) TO '%s' (HEADER, DELIMITER ',' )",
  fname, csv_saida
))
dbDisconnect(con, shutdown = TRUE)
```

Depois de rodar o chunk acima é recomendado dar **Session > Restart R**, para limpar a memória.

1) Carregue os pacotes `readxl` e `tidyverse`.

```
install.packages(c("readxl", "tidyverse"))
```

Installing packages into '/cloud/lib/x86_64-pc-linux-gnu-library/4.6'
(as 'lib' is unspecified)

```
library(readxl)
library(tidyverse)
```

— Attaching core tidyverse packages — tidyverse 2.0.0 —

✓ dplyr	1.2.1	✓ readr	2.2.0
✓ forcats	1.0.1	✓ stringr	1.6.0
✓ ggplot2	4.0.3	✓ tibble	3.3.1
✓ lubridate	1.9.5	✓ tidyr	1.3.2
✓ purrr	1.2.2		

— Conflicts — tidyverse_conflicts() —

✗ dplyr::filter() masks stats::filter()
✗ dplyr::lag() masks stats::lag()

ℹ Use the conflicted package (<<http://conflicted.r-lib.org/>>) to force all conflicts to become errors

2) Crie uma variável chamada `fname` que contenha o caminho para o arquivo `WDIEXCEL.xlsx`, disponível no seu diretório de dados. Confirme que o R identifica a existência do arquivo utilizando o comando

`file.exists`

```
fname <- "dados/WDIEXCEL.xlsx"

file.exists(fname)
```

[1] TRUE

3) Leia a planilha "Country" e armazene no objeto `countries`.

```
countries <- read_excel(fname, sheet = "Country")
```

4) Mantenha apenas os registros de 5 países (Brasil e outros 4 de sua escolha).

```
mantidos <- c("BRA", "CHN", "CUB", "IND", "ITA")

countries <- countries |>
  filter(`Country Code` %in% mantidos)

head(countries)
```

A tibble: 5 × 31

	`Country Code` <chr>	`Short Name` <chr>	`Table Name` <chr>	`Long Name` <chr>	`2-alpha code` <chr>
1	BRA	Brazil	Brazil	Federative Republic o...	BR
2	CHN	China	China	People's Republic of ...	CN
3	CUB	Cuba	Cuba	Republic of Cuba	CU
4	IND	India	India	Republic of India	IN
5	ITA	Italy	Italy	Italian Republic	IT

i 26 more variables: `Currency Unit` <chr>, `Special Notes` <chr>,
 # Region <chr>, `Income Group` <chr>, `WB-2 code` <chr>,
 # `National accounts base year` <chr>,
 # `National accounts reference year` <dbl>, `SNA price valuation` <chr>,
 # `Lending category` <chr>, `Other groups` <chr>,
 # `System of National Accounts` <chr>, `Alternative conversion factor` <lg1>,
 # `PPP survey year` <lg1>, `Balance of Payments Manual in use` <chr>, ...

5) Leia a planilha "Data" e armazene no objeto `WDI`.

```
países_wanted <- countries$`Country Code`

processa_chunk <- function(x, pos) {
  x |>
    filter(`Country Code` %in% países_wanted)
}

WDI <- read_csv_chunked(
  file.path("dados", "WDIEXCEL_Data.csv"),
  DataFrameCallback$new(processa_chunk),
  chunk_size = 20000
)
```

 — Column specification —

```
cols(
  .default = col_double(),
  `Country Name` = col_character(),
  `Country Code` = col_character(),
  `Indicator Name` = col_character(),
  `Indicator Code` = col_character()
)
```

• Use ``spec()`` for the full column specifications.

6) Selecione apenas as colunas:

- Country Code
- Indicator Code
- E todos os anos de 1960-2018

```
WDI <- WDI |>
  select(`Country Code`, `Indicator Code`, `1960`:`2018`)
```

7) Confirme se os dados wm WDI estão em formato tidy. Se não estiverem, transforme-os para tal formato. Faça de forma que exista uma coluna referente ao ano chamada YEAR.

R> A tabela não está em formato tidy pois a variável "year" está armazenada em diversas colunas mas poderia estar em apenas uma.

```
WDI <- WDI %>% #filtra apenas os países selecionados
  filter(`Country Code` %in% countries$`Country Code`)
```

```
WDI <- WDI |>
  pivot_longer(
    cols = `1960`:`2018`,
    names_to = "YEAR",
    values_to = "value"
  ) |>
  pivot_wider(
    names_from = `Indicator Code`,
    values_from = value
  )
```

8) Confirme se a coluna referente ao ano está em formato inteiro.

```
class(WDI$YEAR)
```

```
[1] "character"
```

```
WDI <- WDI %>%
  mutate(YEAR = as.integer(YEAR))

class(WDI$YEAR)
```

```
[1] "integer"
```

9) Para o objeto WDI, mantenha apenas os registros dos países listados em countries. Selecione as colunas:

- Country Code
- Short Name
- YEAR
- SP.DYN.CBRT.IN

```
WDI_final <- WDI %>%
  inner_join(
    countries %>% select(`Country Code`, `Short Name`),
    by = "Country Code"
  ) %>%
  select(`Country Code`, `Short Name`, YEAR, SP.DYN.CBRT.IN)

WDI_final
```

```
# A tibble: 295 × 4
  `Country Code` `Short Name` YEAR SP.DYN.CBRT.IN
  <chr>          <chr>      <int>      <dbl>
1 BRA           Brazil      1960        43.8
2 BRA           Brazil      1961        43.3
3 BRA           Brazil      1962        42.7
4 BRA           Brazil      1963        42.0
5 BRA           Brazil      1964        41.0
6 BRA           Brazil      1965        39.8
7 BRA           Brazil      1966        38.6
8 BRA           Brazil      1967        37.4
9 BRA           Brazil      1968        36.3
10 BRA          Brazil      1969        35.7
# i 285 more rows
```

10) Ordene o objeto de forma que, para cada país, as informações estejam ordenadas por ano.

```
WDI_final <- WDI_final %>%
  arrange(`Country Code`, YEAR)

WDI_final
```

```
# A tibble: 295 × 4
  `Country Code` `Short Name` YEAR SP.DYN.CBRT.IN
  <chr>          <chr>      <int>      <dbl>
1 BRA           Brazil      1960        43.8
2 BRA           Brazil      1961        43.3
3 BRA           Brazil      1962        42.7
4 BRA           Brazil      1963        42.0
5 BRA           Brazil      1964        41.0
6 BRA           Brazil      1965        39.8
7 BRA           Brazil      1966        38.6
8 BRA           Brazil      1967        37.4
9 BRA           Brazil      1968        36.3
```

10 BRA

Brazil

1969


35.7

i 285 more rows

11) Construa um gráfico de linhas, usando o pacote `ggplot2`, que tenha no eixo X a variável YEAR, no eixo Y a variável SP.DYN.CBRT.IN e que cada linha corresponda a um país diferente.

```
ggplot(WDI_final, aes(x = YEAR, y = SP.DYN.CBRT.IN, color = `Short Name`)) +
  geom_line() +
  labs(
    title = "Taxa de natalidade bruta por país (1960-2018)",
    x = "Ano",
    y = "Taxa de natalidade bruta (SP.DYN.CBRT.IN)",
    color = "País"
  ) +
  theme_minimal()
```

Taxa de natalidade bruta por país (1960-2018)



```
Sys.setenv(TZ = "America/Sao_Paulo")
Sys.time()
```

[1] "2026-09-09 22:43:29 -03"